基于产业异质图网络的专利分类研究

A Research on Patent Classification Using Industrial Heterogeneous Graph Network

张鼎

武汉大学计算机学院

Oct. 26 2021

Outline

研究背景

- 专利指标已经成为国家竞争力和科技创新能力的重要标志。
- 在通常情况下，专利审查员会根据其具有的领域知识手工将每个专利手动分为多个类别。
- 专利申请迅速增长，传统的手动操作费力费时，几乎无法满足需求。
- 迫切需要自动专利分类工具来支持相关服务。
- 专利的自动分类对于提高大规模专利管理和服务的效率具有重要意义。

Outline

相关工作

目前关于专利自动分类的相关研究大致可以分为两个方面：

- 挖掘有效的特征
- 设计专用的分类器

相关工作

目前关于专利自动分类的相关研究大致可以分为两个方面：

- 挖掘有效的特征
  - 专利文档中含有大量的元特征以及文本信息，通过从中挖掘有效的特征对专利进行分类。
  - 文档分割及语法分析
  - 关键词提取
  - 文本聚类
- 设计专用的分类器
  - SVM，KNN，CNN，GRU，BERT 等方法被引入来解决专利自动分类问题。
  - DeepPatent 建立了深度卷积神经网络模型，并结合词嵌入对专利文件进行分类。
  - PatentBert 利用了功能强大的预训练语言模型 Bert，然后对其进行微调以处理多标签专利分类问题。

Outline

Outline

创新点
多视图
整体架构

当前挑战与问题

- 现在使用最多的专利分类数据集为 USPTO 数据集，为英文专利数据集。缺少一个大规模的中文专利分类数据集。
- 现有的专利分类器专注于从专利本身内容抽取特征，忽略了专利发明人、公司之间的关联信息。
- 专利文本分类方法需要使用到专利全文数据，涉及到大量的专有名词，特征提取难度大。且当数据规模量大后，模型的计算效率会降低，计算资源、显存消耗量显著变大。

Outline

创新点

- 以图的视角切入专利分类的问题，不需要用到专利全文数据进行分类。避免了原来专利分类在大数据集上分类速度降低、使用资源显著变大的问题。
- 提出了一种多视图融合的异质图神经网络，可以同时捕捉到局部（专利本身）和全局（公司、产业之间）的语义信息，利用注意力机制，将不同视图下的信息进行有效的聚合。

Outline

多视图

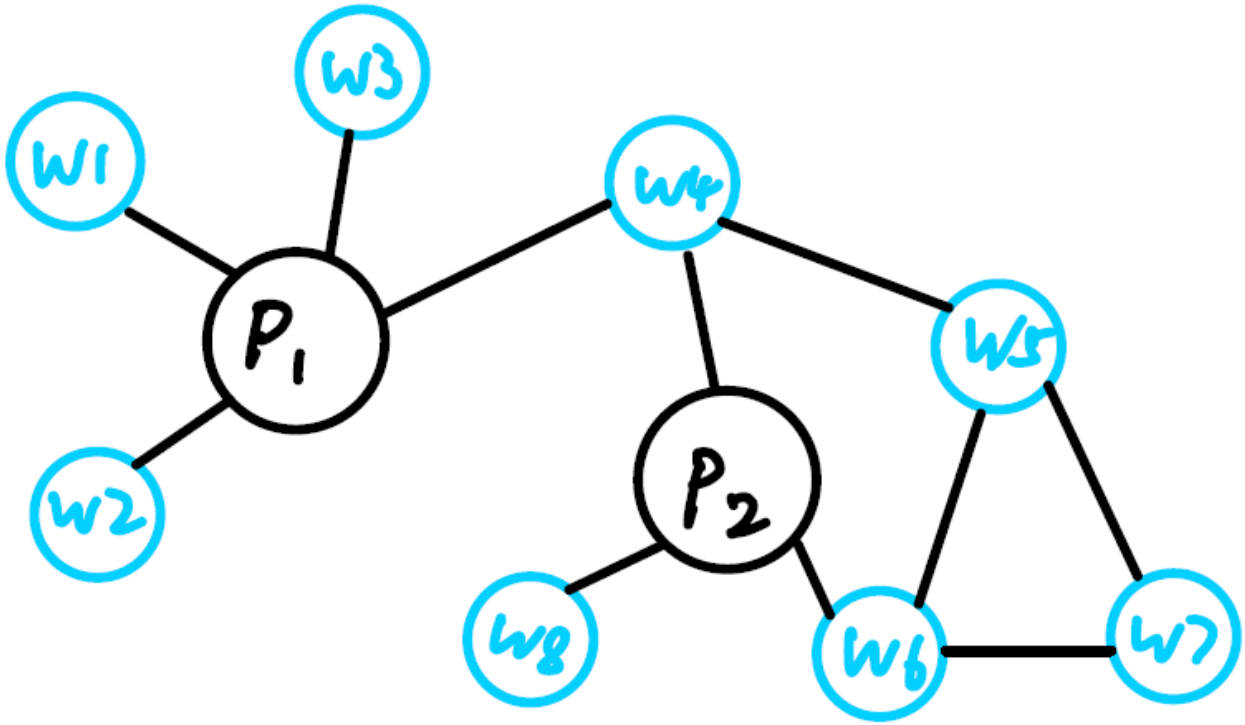

多视图

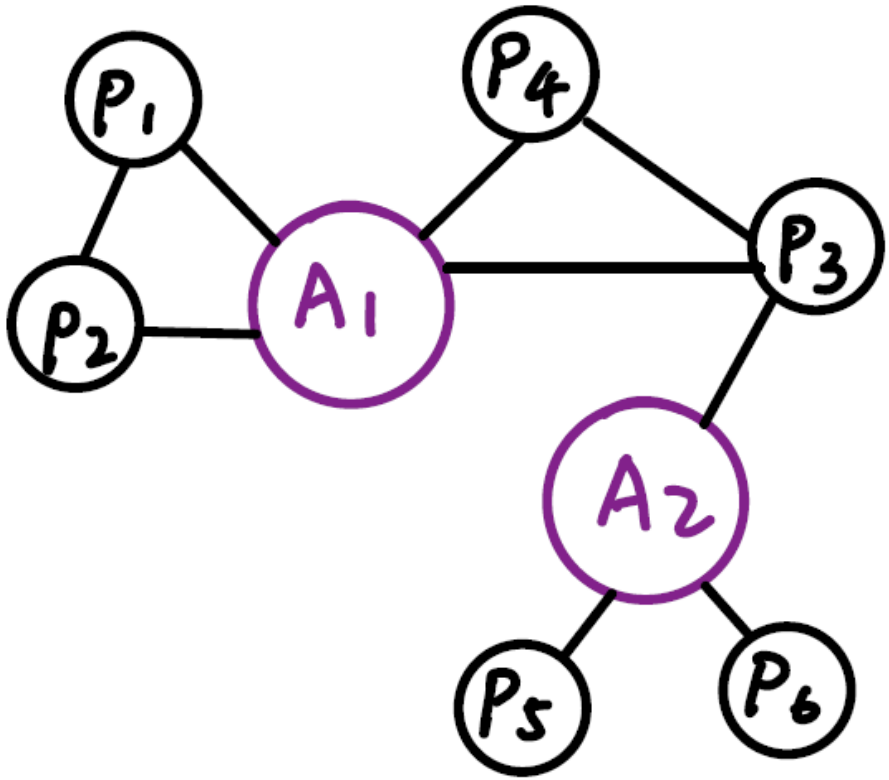

多视图

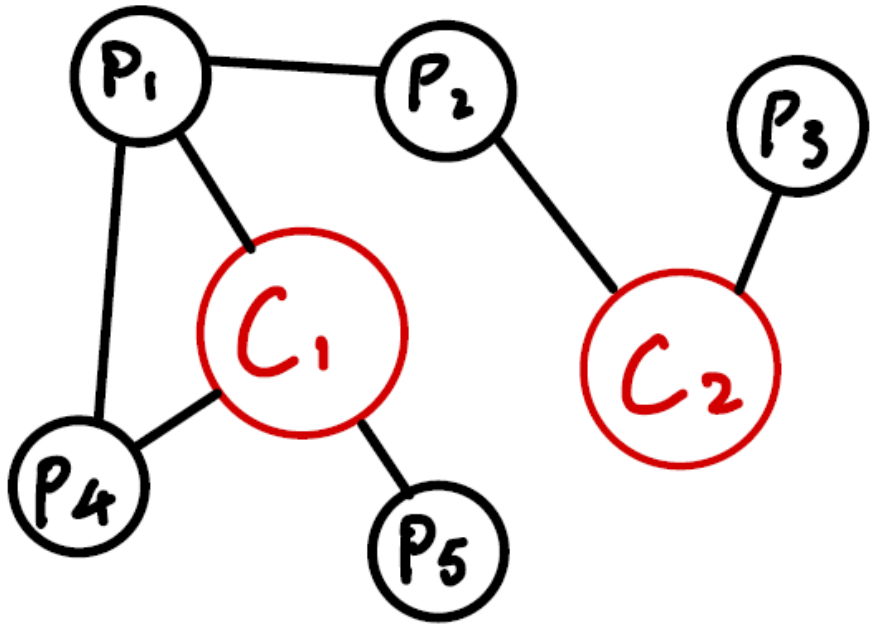

多视图

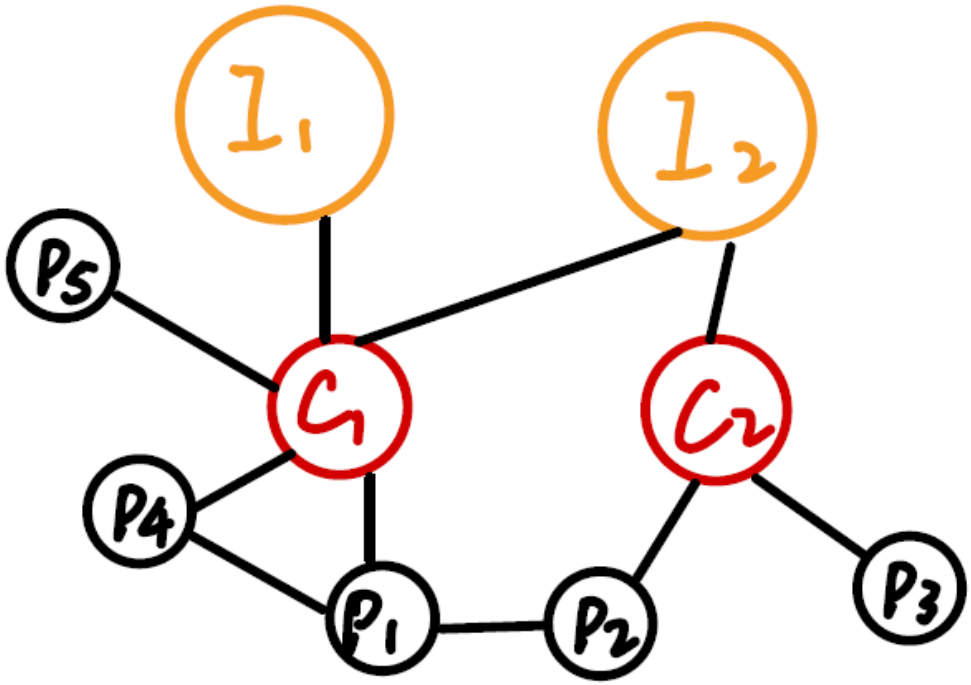

Outline

整体架构

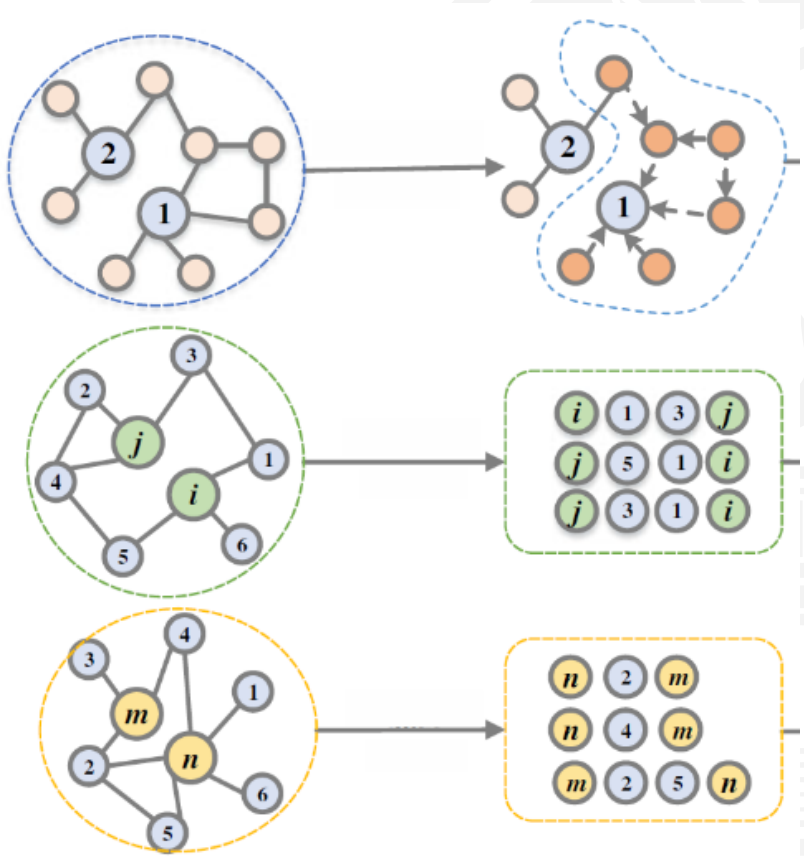

整体架构

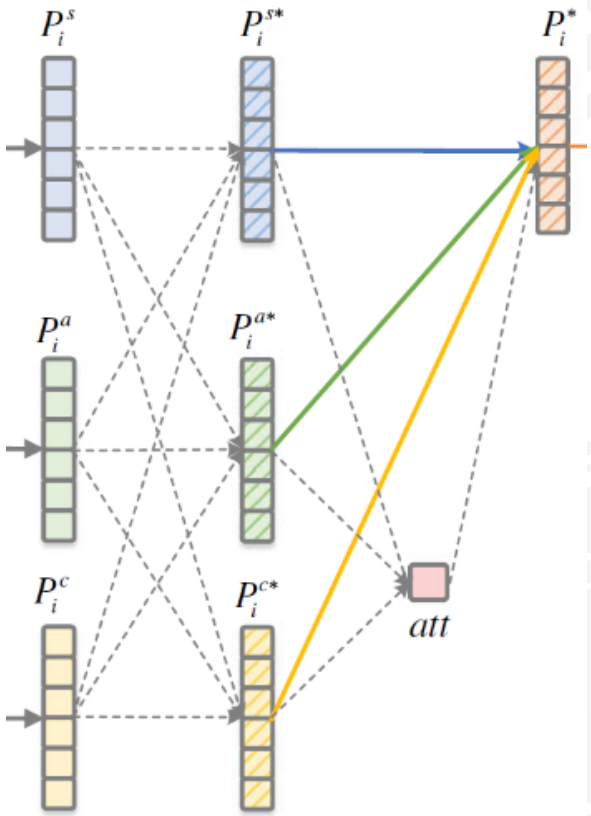

整体架构

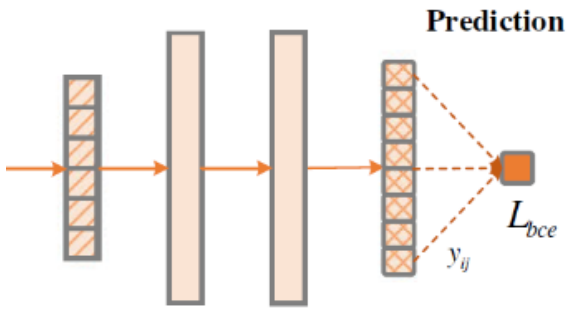

Outline

Outline

1. 实验数据
   - 130w+ 条专利数据与公司产业数据，构建产业异质图数据集。
   - 异质图节点包含：专利、发明人、公司、产业
2. 评价指标
   - Precision@K
   - Recall@K
   - Precision Recall 曲线 AUC 值
3. 对比模型
   - 基于文本分类：Bi-LSTM
   - 基于文本分类：DeepPatent
   - 基于文本分类：PatentBert
   - 基于图：Deepwalk
   - 基于图：Node2vec
   - 基于图：GCN
4. 对比实验
   - 验证多视图的有效性

Outline

Outline

论文提纲

1. 绪论
2. 专利分类相关理论与技术
3. 基于产业的图结构编码
4. 基于产业异质图神经网络的专利分类
5. 实验与结果分析
6. 总结与展望

论文提纲

Outline

时间安排

时间	安排
2021 年 10 月	论文选题，查阅相关文献资料，撰写开题报告。
2021 年 11 月-2022 年 01 月	设计模型细节，数据预处理。
2022 年 01 月-2022 年 02 月	编写代码，实现模型。
2022 年 02 月-2022 年 04 月	验证模型的性能，做对比实验，完善相应算法。
2022 年 04 月-2022 年 05 月	根据实验结果撰写论文初稿。
2022 年 05 月	论文修改、定稿，参加答辩。

感谢聆听

敬请各位老师批评指导

答辩人：张鼎